2026 FinTechathon 深圳国际金融科技大赛

数据分析赛道 · 赛题三

从公开口碑到复核决策：餐饮商户经营风险指标构建与验证

——可解释画像、预算验证与日期偏差审计

小组名称：待填写

摘要

针对小微餐饮主体财务信息稀缺的问题，本文研究公开口碑信息能否补充经营风险画像。基于某生活服务平台的海外历史区域子集，筛选674家餐饮商户，其中123家记录为停止营业；围绕口碑质量、评论活跃度和低分评论主题构建12项指标，比较逻辑回归与梯度提升树的六种输入组合，并进行独立测试和人工复核预算模拟。按验证集确定的增强逻辑回归，测试ROC-AUC为0.577、平均精确率AP为0.220；相对评分质量基线的AP增量为0.009，95%配对Bootstrap区间包含0。预设增强树模型AP为0.319，在复核14家测试商户时命中7家停止营业商户，相对随机名单的点估计提升2.70倍，但区间仍包含无提升的可能。补充同年份配对审计后，增强树模型AUC由0.631降至0.488，提示总体优势可能受年代结构影响。本文形成“画像—复核—反馈”的产品闭环与收益检验条件；结果支持调查线索构建，尚未证明前瞻经营或信用风险识别增益。

关键词：公开数据；餐饮商户；经营风险画像；营业状态；人工复核

一、业务背景与研究问题

小微经营主体现金流缓冲有限，传统财务风控又依赖标准化报表和信用记录。生活服务平台的公开评价覆盖消费体验、商户活跃度及经营环境，为信息稀疏主体提供了另一条观察路径。但公开评分与经营风险的关系可能受到平台选择、商户规模和时间结构影响，必须用独立样本验证，不能把低评分直接等同于高信用风险。

研究依次回答“信息能否量化、量化是否有效、有效是否值得使用”：构建口碑、活跃度及主题指标；相对评分基线检验增量；在固定核查预算下验证排序价值。贡献在于将指标构建、保留测试、预算验证和日期偏差审计串联，形成可复验的决策证据链。研究以餐饮商户为代理，以公开营业状态作替代验证标签。

赛题强调在经营流水基础上引入公开信息。本研究未获得真实流水，因此检验的是公开信息的独立识别价值，尚未验证其对流水模型的增益。样本也缺少企业规模和贷款表现，餐饮商户仅作为小微主体的研究代理。停业可能来自搬迁或主动退出等原因，不等于财务困境。

二、数据介绍与样本清洗

原始来源为某生活服务平台的学术开放数据[1]，实际使用其社区发布的区域子集[2]。子集以城市名称包含“leveland”的规则筛选，覆盖Cleveland及邻近区域。本研究固定数据来源提交并校验两个输入文件，独立计算指标和模型，没有复用来源项目的模型结果。商户表含类别、城市和营业状态；评论表含商户ID、日期、评分和文本。

原始数据含3,164家商户、91,057条评论。评论日期为2005年4月15日至2017年7月26日，营业状态的采集日期未说明。1,361家餐饮商户中，318家标记停止营业；其评论共64,693条。按照评价数量、历史跨度及近期可观测性逐步筛选，最终纳入674家，其中营业551家、停止营业123家，停止营业占比18.25%。

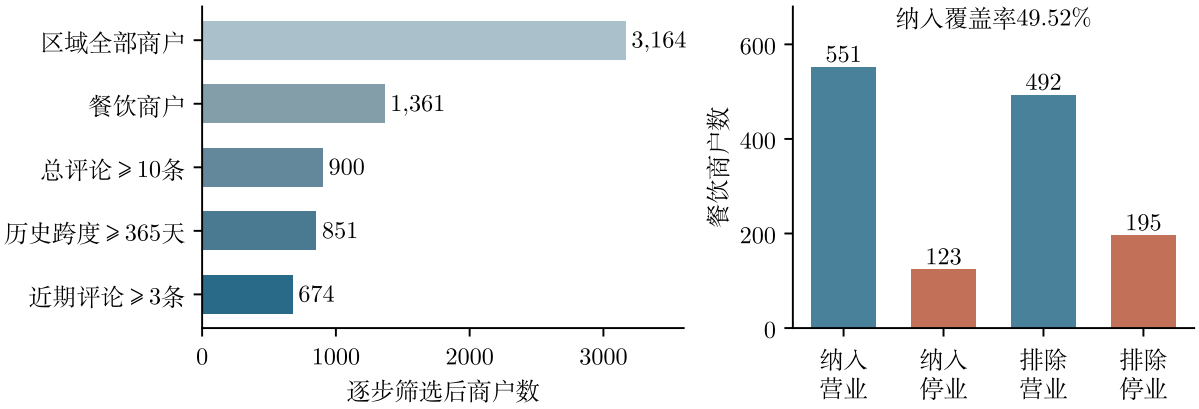


图1 样本筛选及纳入 / 排除商户的营业状态

表1 数据质量与样本纳入规则

核对项目	结果或处理规则
商户与评论关联	商户ID无重复；评论ID无重复；评论均匹配商户
日期与评分	无无效日期；评分均处于1—5分
纳入门槛	总评论 ⩾ 10条；历史跨度 ⩾ 365天；近180天评论 ⩾ 3条
计数一致性	64家商户表总评论数与实际评论数不一致，原因未确认
计数处理	所有计数从实际评论重新计算，不使用商户表总数

样本含核心城区635家、邻近城区39家，覆盖原餐饮商户49.52%，只覆盖原停业商户38.68%。未纳入的687家中195家停业，占28.38%，高于纳入组18.25%。门槛提高可观测性，却排除较多停业主体；信息不足应进入补资料流程，不能标为低风险。图表仅展示匿名聚合结果。

三、指标体系与描述性分析

以各商户最后一条评论日期作为历史窗口锚点：近360天为距锚点0—359天，近期与前期分别为0—179天和180—359天。窗口不对应统一日历时间，本设计属于历史横截面比较。机制假设是：体验恶化可能伴随需求流失，关注度波动可能提示经营不稳定，低分主题提供核查方向；评论不是现金流。按三类构建12项指标（表2），预期方向仅作研究假设，不硬编码为风险加分。

表2 三维经营风险画像指标体系

维度	指标（每维4项）	业务含义
口碑质量Q	近360天均分、低分占比、评分标准差；近期较前期均分变化	衡量消费者评价水平、分歧及变化
评论活跃度A	近期/前期评论数；数量对数变化；六个30天窗口数量变异系数	衡量平台消费关注度及波动
低分主题T	近期低分且提及服务、卫生、价格、食物问题的评论占比	识别可供调查核实的经营体验线索

数量变化定义为log(1+近期数量)-log(1+前期数量)。低分指评分不超过2分；各主题以固定词典匹配，分母为近期全部评论数。40家商户前期窗口无评论，其均分变化记为缺失，在拟合数据上作中位数填补并增加缺失指示。低分主题只是词语提及，并非经人工确认的投诉。拟合样本均分与低分占比Spearman相关为-0.934，近期与前期评论数为0.736；相关指标的回归符号不能单独解释为风险方向或因果效应。

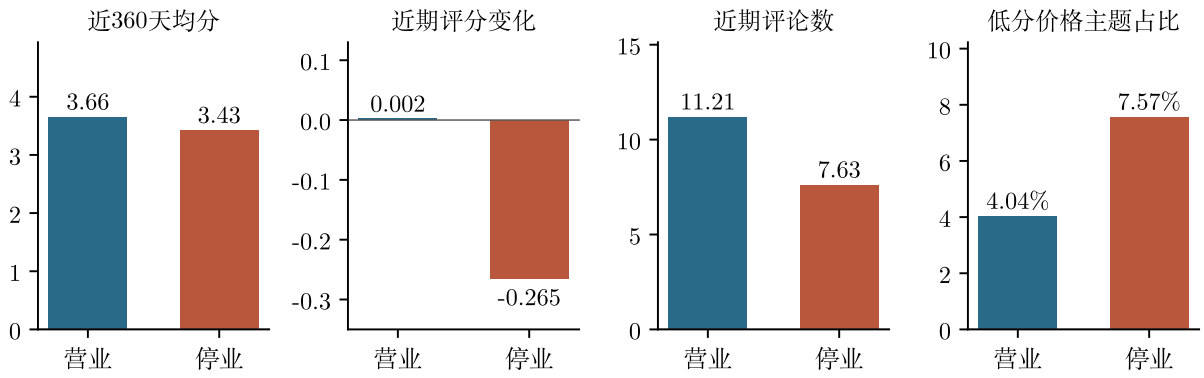


图2 营业与停止营业商户的主要指标均值（全样本探索性描述）

停止营业商户近360天均分为3.43，营业商户为3.66；近期评分变化均值分别为-0.265与0.002。近期评论数均值分别为7.63与11.21，但两组中位数均为7，说明分布偏态。12项Mann–Whitney检验作Holm校正后，仅均分和价格主题在0.05水平有差异（校正p=0.0065、0.0487）；评分变化p=0.0538，卫生主题未呈预期方向。描述差异不等于独立预测价值，主题提及也不代表因果关系。

四、模型分析与验证设计

以商户表记录的停止营业为正类，营业为负类。按商户独立、标签分层，一次固定划分训练、验证、测试集合，随机种子为20261011。同一商户不会跨集合，测试集保留到参数与主分析方案确定后使用；划分比例为60%/20%/20%，见表3。

表3 样本划分与标签构成

集合	商户数	停止营业数	占比
训练集	404	73	18.07%
验证集	135	25	18.52%
测试集	135	25	18.52%

采用逻辑回归（LR）作解释性基线，以及直方图梯度提升树（HGB）检验非线性关系。每种算法均比较Q、Q+A、Q+A+T三组输入，共六个预设模型，以分离评分、活跃度与评论主题的增量。没有将当前营业状态文字、关闭词汇、最后评论年份或距数据末日的无评论天数放入模型。

逻辑回归在C=0.1、1、10中选择正则强度；树模型比较最大叶节点7、15及L2系数1、5，固定150次迭代、学习率0.05、每叶最少20个样本。每种算法与指标组仅用验证集平均精确率AP选参数，再合并训练和验证集重新拟合。逻辑回归标准化、所有缺失填补及缺失指示均只在拟合数据估计。

质量基线在LR · Q与HGB · Q中按验证集AP选择，增强方案在LR · QAT与HGB · QAT中同样选择。由此主分析基线为LR · Q，主分析增强模型为LR · QAT。增强树模型虽然测试表现较好，但没有据此回头改选为主模型。全部预设模型均保留，并明确区分主分析与探索比较。

验证使用ROC-AUC、平均精确率AP和有限预算下的复核命中率、捕获率及提升倍数。AP采用非插值平均精确率，不混用梯形积分PR面积；测试停止营业比例18.52%作为随机排序AP的总体参考。对测试商户作1,500次配对Bootstrap，报告百分位95%区间；该区间不涵盖训练重拟合、模型选择或外部地区的不确定性。

五、模型结果与增量价值

六个模型的独立测试点估计和Bootstrap区间见图3。质量基线LR · Q测试ROC-AUC为0.545、AP为0.211；主分析增强LR · QAT分别为0.577和0.220。加入活跃度与主题后的改善较小，不能据此声称公开信息已显著提升风险识别。

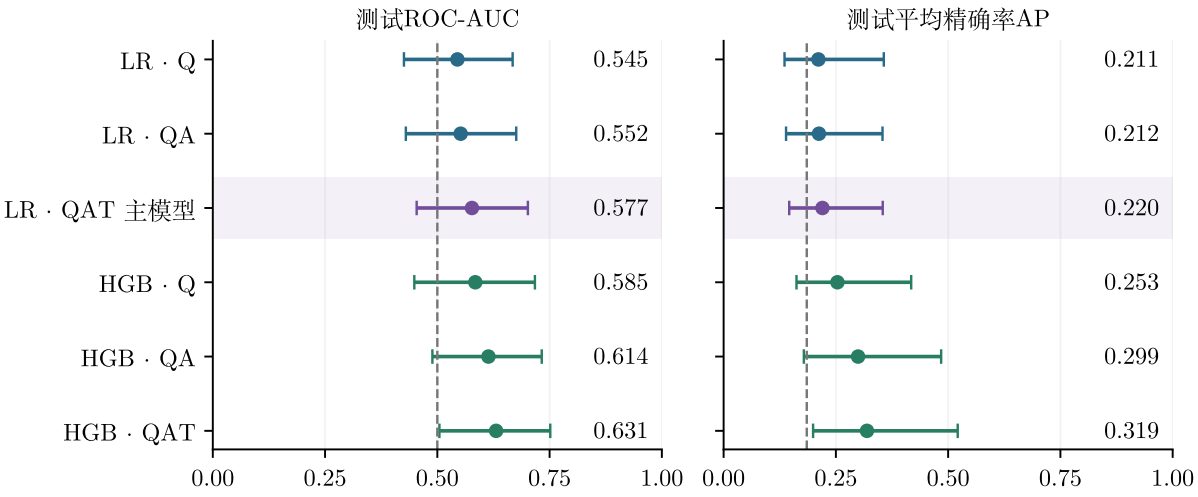


图3 六个预设模型的测试表现及95%Bootstrap区间；虚线为随机参考

表4 预设模型的验证与测试结果

模型	验证AP	测试ROC-AUC	测试AP	Brier↓
LR · Q	0.301	0.545	0.211	0.1635
LR · QA	0.320	0.552	0.212	0.1681
LR · QAT（主模型）	0.344	0.577	0.220	0.1663
HGB · Q	0.259	0.585	0.253	0.1590
HGB · QA	0.323	0.614	0.299	0.1593
HGB · QAT	0.304	0.631	0.319	0.1519

主模型相对质量基线的AP增量为0.0091，配对95%区间为[-0.055，0.064]。增强树模型相对其质量基线的AP增量为0.0658，区间为[-0.038，0.185]。两者均包含0，无法排除无增益的情况。树模型中QA相对Q、QAT相对QA的AP点估计均有所增加，可作为扩大样本后进一步验证的线索。

Brier为预测概率与标签的均方误差，越低越好。只用拟合期停业比例18.18%作常数预测，测试Brier为0.1509，主模型0.1663、增强树0.1519，均未优于此概率评分基线。因此分数仅作历史排序，不展示为风险概率。测试只有25家停业，多模型比较未校正，均按探索性证据理解。

六、应用验证：有限预算下的人工复核

设定金融机构每期只能核实约10%的商户。对135家测试商户向上取整选14家，实际预算比例为10.37%，对比随机抽查、最低评分筛选、主分析方案及预设增强树模型。停止营业标签仅用于事后核对名单，未用于选择名单或调整模型参数。

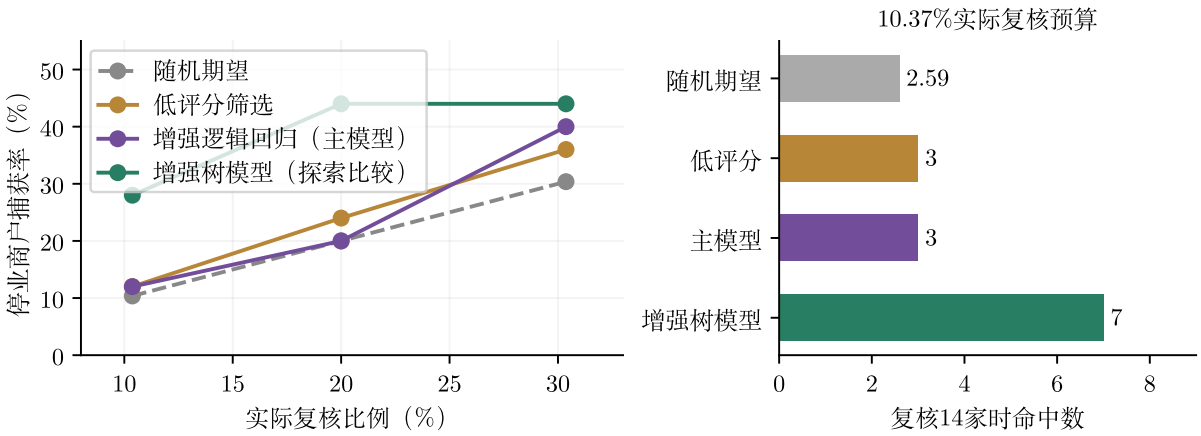


图4 不同复核预算下的停业商户捕获率及约10%预算的命中数

表5 复核14家测试商户的模拟效果

策略	命中数	名单命中率	停业捕获率	提升倍数
随机抽查（期望）	2.59	18.52%	10.37%	1.00
低评分筛选	3	21.43%	12.00%	1.16
质量基线LR · Q	3	21.43%	12.00%	1.16
主模型LR · QAT	3	21.43%	12.00%	1.16
增强树模型HGB · QAT	7	50.00%	28.00%	2.70

随机名单2.59家为理论期望，不是某次抽查实际命中了小数家。主模型与低评分名单均命中3家，未表现出额外复核效率。增强树模型命中7家，提升倍数点估计为2.70，但95%区间为[0.96，3.75]，包含1；模型相对随机的优势仍需独立复验。此树模型属于预设探索比较，不能因测试表现高而追认为已定型的部署模型。

增强树模型在约10%预算下仍漏掉72%的停止营业商户，且名单中一半商户仍在营业。因此这类输出更适合安排低成本人工核实，而非直接拒贷。该模拟也没有衡量真实违约、回收损失、核查成本或干预效果，不能将点估计转化为确定的商业收益。

七、偏差检查、敏感性与研究限制

营业与停止营业组的最后评论年份存在明显差异：551家营业商户中528家最后评论在2017年，123家停止营业商户中只有6家在2017年。图5展示这一结构与固定预测的追加日期审计。虽未输入年份，窗口年代仍可能影响评论量和消费行为；排除直接日期变量不能保证已消除混杂。

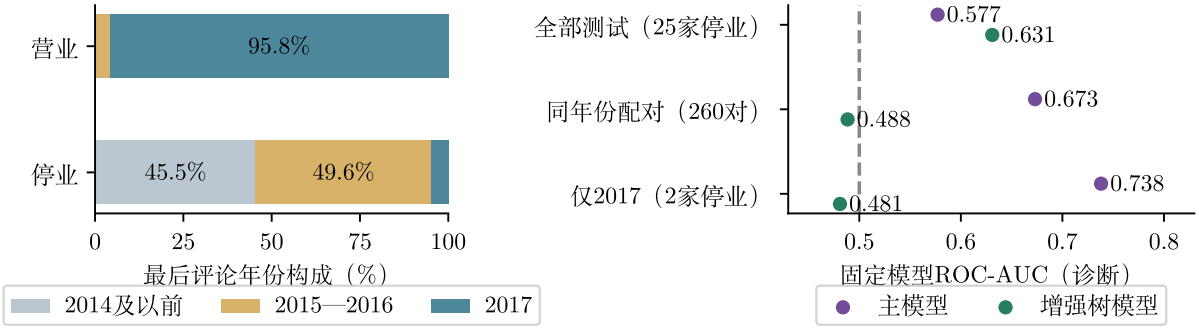


图5 日期结构及追加同年份审计（事后诊断，未重新拟合）

只比较同一年内停业—营业配对，共260对，主模型AUC为0.673，增强树为0.488；仅2017年107家（停业2家）时分别为0.738、0.481。树模型总体优势未在日期限制下保留，主模型较高子组分数也因事件极少而不稳定。该审计在原结果之后设计，未调参，不能作为确认性证据。原2015年及之后子样本主模型AUC仅0.525，仍需独立复验。

标签边界：没有关闭日期、统一状态采集日期、贷款逾期或真实流水，无法验证评论在风险事件之前可用。随机商户划分只检验同类历史记录的状态识别，不代表跨时间预警能力。停业也不能直接作为违约标签。

样本边界：平台消费者并非全部客群，评价数不等于营业额。历史跨度不足或锚点前半年评论较少的主体被排除；企业规模、连锁关系和评论真实性尚未核验。词典主题只反映低分评论中的话题提及，不是精确投诉归因。

外推与使用边界：评论截至2017年，海外区域样本不能证明2026年深圳小微企业适用性。当前官方数据协议及该镜像的再分发授权尚待核实，2015年历史协议[3]不能代替当前许可。本报告不披露原始评论及具名商户，正式提交前应确认教育比赛使用范围。

八、产品思路与商业应用

产品定位为“小微商户经营线索助手”，向银行客户经理输出“调查优先级＋触发指标＋可信度”。无足够评论时显示信息不足；有线索时核实经营和实际流水。画像可上线为信息展示，模型排序暂不进入自动授信。指标异常仅作核查理由，不当作真实经营问题的确证。

表6 产品闭环：证据、动作与反馈

环节	当前证据 / 输出	业务动作与回流
可观测性	样本覆盖49.52%；更新日未知	未覆盖商户补资料，单独保留随机核查
可信度	12项指标；主题及概率未充分验证	展示指标和来源，不显示违约概率
人工调查	主模型未优于低评分复核名单	仅作试点线索；核实流水与经营状态
反馈验收	目前无未来标签及真实成本	记录确认结果、耗时、处置及后续表现

商业评价以每期复核k家为单位：净价值=$k\times(p\times v-c)-F$，其中p为前瞻验证的可行动风险命中率，v为每次有效发现的净收益，c为单家核查成本，F为期间固定成本。相对同预算低评分名单，增量价值=(命中差)$\times$v-新增固定成本。本次主模型命中差为0，树模型为4，但停业命中不能代替可行动风险，不能据此估算节省金额。

九、总结结论

本研究形成三维12项画像，但没有证明稳定的排序增量或概率评分优势。核心业务结论是：先按可观测性分流，再按预算检验排序，最后以未来标签和净价值验收。仅49.52%的商户满足指标门槛，未覆盖组停业比例更高，故低数据覆盖不能被误当成低风险。增强树的高点估计未通过日期审计；当前建议保留画像与人工调查，不部署自动风险决策。

下一阶段在已获许可前提下，以统一月末为观察点，之后90天独立核实停业、搬迁及经营困难；逾期另设信用标签。训练标签须在测试观察日前成熟，未知 / 失访不得记为正常。锁定流水基线与流水＋公开指标、10%预算和成本口径；留出后续月份 / 新地区，未覆盖商户也进入随机核查。只核查模型名单无法估计全量漏报，须借助独立标签或已知抽样概率的对照。记录有效发现、误报、漏报、耗时及干预；每月监测覆盖率和指标分布。增量区间下界>0且净价值>0才扩大，否则退回人工补资料。以上是待执行方案。

参考文献与数据来源

[1] Yelp. Yelp Open Dataset[EB/OL]. https://www.yelp.com/dataset. 官方当前使用条款在本次研究中尚未核实。

[2] Cleveland区域公开子集及筛选说明[DS/OL]. https://github.com/ahegel/yelp-dataset. 本研究固定提交e5b82be3c909f9bb45dfd03e164ae0b7897832bd；评论截至2017年7月26日，营业状态采集时间未说明。

[3] Yelp. Dataset Challenge Academic Dataset Terms of Use[EB/OL]. 更新日期2015-03-23. 历史协议归档来源：https://github.com/vc1492a/Yelp-Challenge-Dataset. 固定提交0402872665e57c253ba7dcbb71b10842bc1ef08a；文件位于该仓库Raw Data目录，题名为Dataset Challenge Academic Dataset Agreement。该历史归档不证明当前授权。

[4] scikit-learn. Model evaluation: quantifying the quality of predictions; LogisticRegression; HistGradientBoostingClassifier[EB/OL]. https://scikit-learn.org/stable/. 本研究AP采用average_precision_score的非插值平均精确率定义。

[5] Efron B, Tibshirani R J. An Introduction to the Bootstrap[M]. New York: Chapman & Hall, 1993.

[6] Holm S. A Simple Sequentially Rejective Multiple Test Procedure[J]. Scandinavian Journal of Statistics, 1979, 6(2): 65–70.